Nhập Môn Khoa Học Dữ Liệu

Đề tài: Phân loại đa nhãn review phim

GVHD: Thầy Nguyễn Ngọc Duy

Thành Viên - Nhóm 04

Lê Trung Nguyên

N21DCCN057

Hà Gia Huy

N21DCCN038

Trần Bình Phương Nhã

N21DCCN059

Nội Dung Bài Báo Cáo

01 Giới thiệu đề tài

02 Xây dựng bộ dữ liệu

03 Xử lý dữ liệu và trích xuất đặc trưng

04 Huấn luyện và đánh giá mô hình

Phần 01.

Giới thiệu đề tài

Tổng quan về đề tài

Nhiệm vụ phân loại đa nhãn review, đánh giá của người xem về phim nhằm mục đích xác định những trải nghiệm, suy nghĩ khác nhau của người xem về các bộ phim mà họ đã thưởng thức.

Các tiến bộ trong lĩnh vực NLP và công nghệ thông tin đã tạo điều kiện cho sự ra đời của các ứng dụng mới, đồng thời mở rộng không gian nghiên cứu dựa trên dữ liệu văn bản ngày càng phong phú. Phân loại văn bản là một trong những bài toán cơ bản của NLP.

Có nhiều cách phân loại văn bản trong NLP, nếu dựa trên số lượng nhãn được gán cho mỗi văn bản, có thể chia phân loại văn bản thành 2 loại là phân loại nhị phân (Binary) hay phân loại đa lớp (Multi-class) và phân loại đa nhãn (Multi-label).

Đối với ngữ cảnh cần thu thập ý kiến người dùng về một sản phẩm hay vấn đề, bài toán phân loại nhị phân hay đa lớp sẽ tỏ ra kém hiệu quả vì ngôn ngữ được dùng trong những trường hợp này phức tạp hơn, gắn nhãn đơn lẻ sẽ làm hạn chế khả năng trích xuất thông tin.

Thuật toán học máy sử dụng trong đề tài

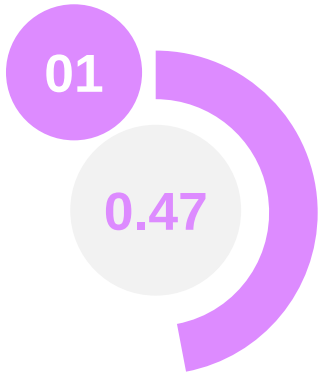

Naïve Bayes

NB là một thuật toán máy học được dựa trên định lý Bayes về giả định tính độc lập giữa các đặc trưng.

K-Nearest Neighbors

KNN là thuật toán đi tìm đầu ra của điểm dữ liệu bằng cách chỉ dựa trên thông tin của K điểm dữ liệu trong training set gần nó nhất.

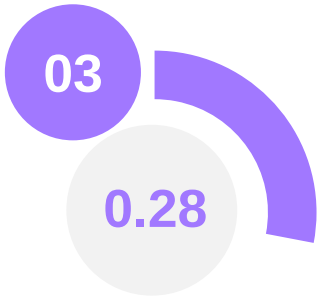

Support Vector Machine

SVM là một mô hình phân loại hoạt động bằng việc xây dựng một siêu phẳng trong không gian n chiều sao cho nó phân loại các lớp một cách tối ưu nhất.

Random Forests

RF tạo ra cây quyết định trên các mẫu được chọn ngẫu nhiên, tiến hành dự đoán riêng và chọn giải pháp tốt nhất bằng cách bỏ phiếu.

Logistic Regression

LR là một phương pháp phân tích quan hệ giữa biến phụ thuộc Y với một hay nhiều biến độc lập X.

Phần 02. Xây Dựng Bộ Dữ Liệu

Thu thập dữ liệu và chọn nhãn

Nhãn cảm động (touching)

Liên quan đến yếu tố cảm xúc “cảm động” mà bộ phim có thể mang đến cho người xem. VD: “xem xong khóc muốn trôi rạp”

Trang review movie của MOMO

https://www.momo.vn/cinema/review
Sau khi thu thập và sàn lọc, chúng tôi thu được bộ dataset có **5530** dòng dữ liệu và được phân loại dựa vào **5** nhãn

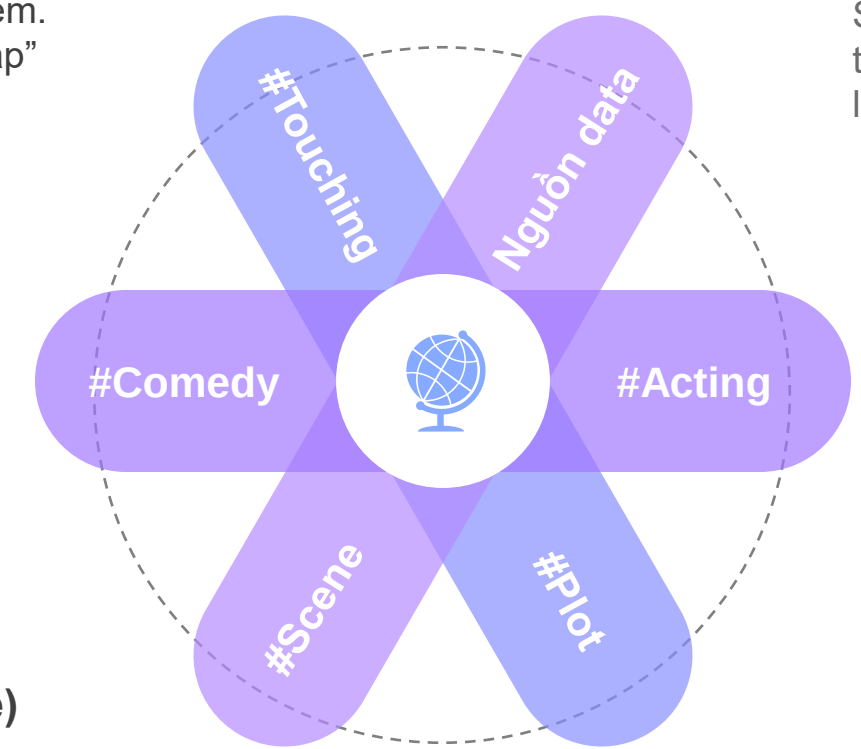

Nhãn hài hước (comedy)

Liên quan đến yếu tố cảm xúc “hài hước” mà bộ phim có thể mang đến cho người xem. VD: “phim hài thiệt sự, coi mà cười đau cả bụng”

Nhãn diễn xuất (acting)

Liên quan đến yếu tố diễn xuất của các diễn viên. VD: “nhân vật Chú Ba diễn rất hay và nhập tâm”

Nhãn góc quay, kỹ xảo (scene)

Liên quan đến yếu tố bối cảnh, góc quay, kỹ xảo được sử dụng trong phim. VD: “công nhận CGI đỉnh thật, quá choáng ngợp”

Nhãn bối cảnh, cốt truyện (plot)

Liên quan đến yếu tố cốt truyện, kịch bản, nội dung phim. VD: “kịch bản có nhiều plot twist, làm người xem bất ngờ”

Quy trình đánh nhãn và tạo dataset

Thu thập và sàng lọc sơ bộ, loại bỏ bớt các dòng dữ liệu không liên quan hoặc bị thiếu nội dung trong quá trình thu thập

2 thành viên trong nhóm sẽ tiến hành gán nhãn cho 2 bản copy của dữ liệu (độc lập với nhau)

Tổng hợp lại thành 1 bộ dữ liệu chung. Các nhãn khác nhau sẽ được thảo luận và gán nhãn lại

Tiến hành sàng lọc lại, tiếp tục loại bỏ các bình luận có nội dung spam, không phù hợp,…

Thành viên thứ 3 tiến hàng xử lý mất cân bằng nhãn.

Sau bước xử lý mất cân bằng, chúng tôi thu được file Excel gồm 5530 dòng, file sau đó được chuyển đổi sang định dạng CSV.

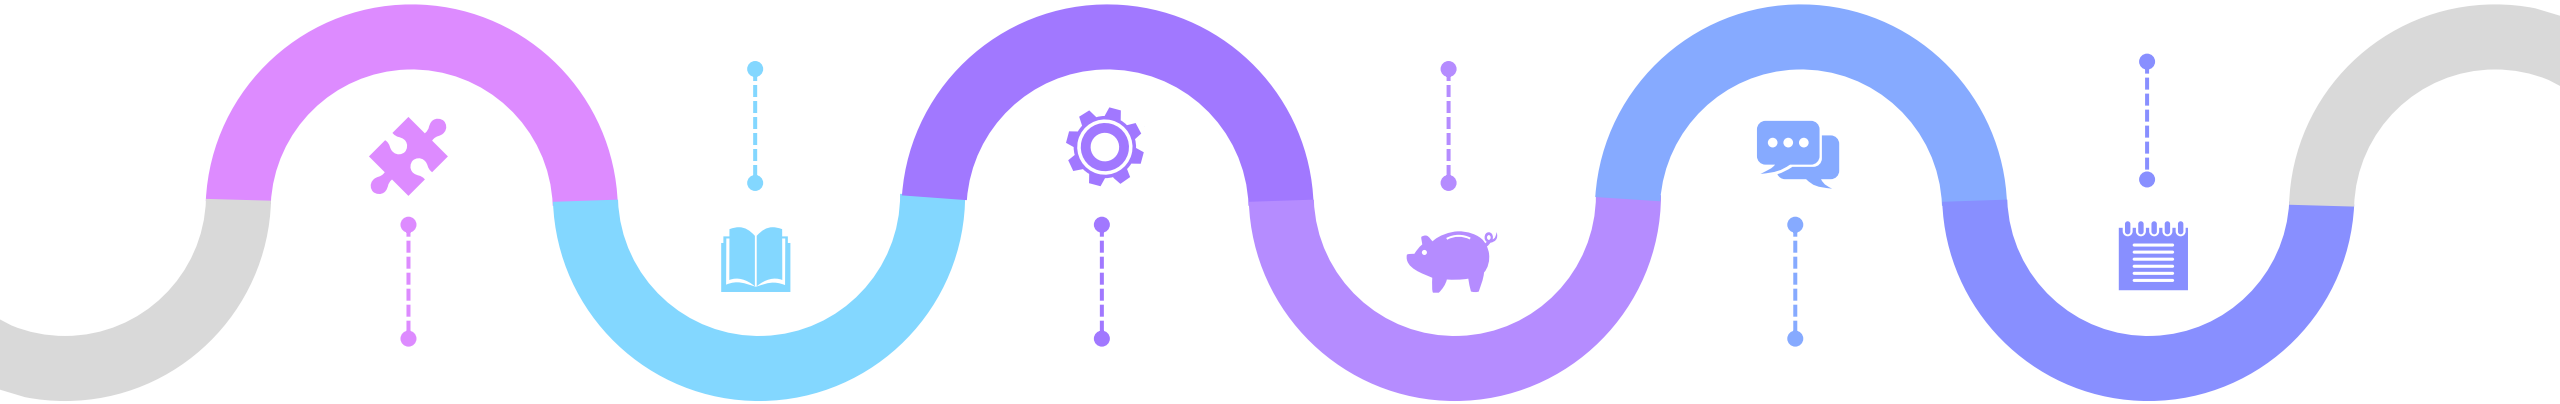

Trực quan hóa dữ liệu

Nhận xét #plot

Nhãn cốt truyện (plot) có tần suất xuất hiện cao hơn, bởi cốt truyện, kịch bản là yếu tố then chốt quyết định chất lượng của hầu hết bộ phim.

Các nhãn mang yếu tố cảm xúc

Ngoài phụ thuộc vào thông điệp và khả năng truyền tải cảm xúc của bộ phim, các nhãn mang yếu tố cảm xúc còn phụ thuộc vào cảm nhận cá nhân của khán giả.

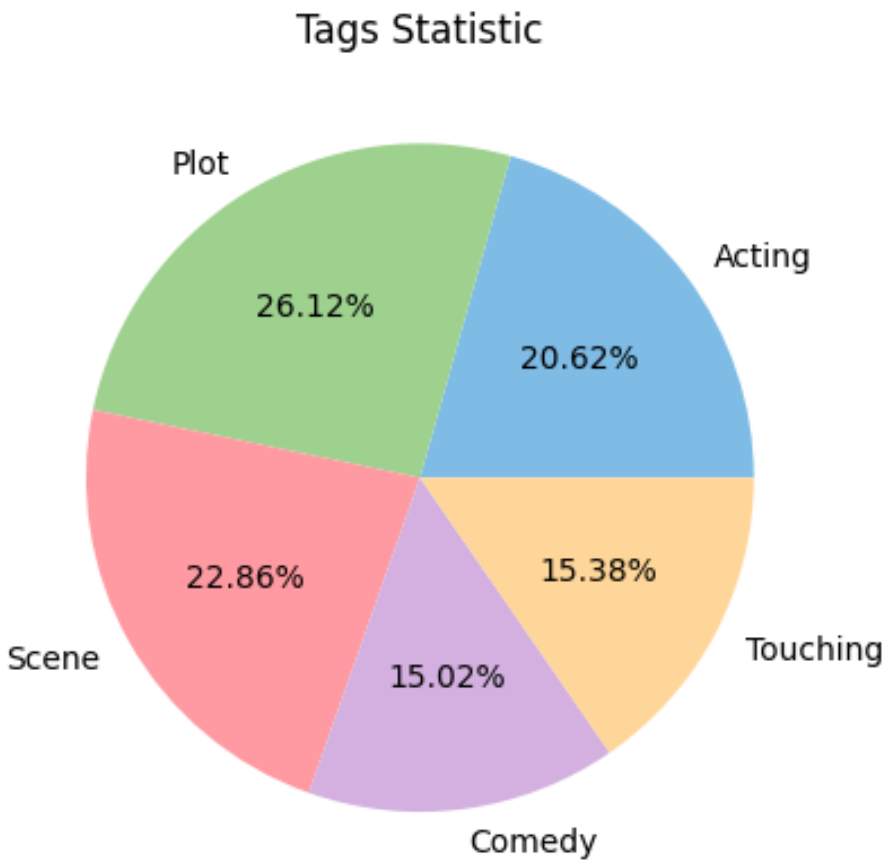

Nhận xét #comedy #touching

Các nhãn hài hước (comedy) và cảm động (touching) có tuần suất xuất hiện thấp nhất, vì nó có liên quan mất thiết đến chủ đề, thông điệp và khả năng truyền tải cảm xúc của bộ phim nên không phải phim nào cũng được đề cập.

Sự liên quan #acting và #plot

Dựa vào dataset, các review có đề cập yếu tố diễn xuất (acting) hoặc yếu tố bối cảnh (scene) thường cũng nhắc đến yếu tố cốt truyện (plot).

Phần 03.

Xử lý dữ liệu và trích xuất đặc trưng

Biến đổi dữ liệu thô

Xóa các ký tự đặc biệt, biểu tượng cảm xúc và xóa các ký tự không cần thiết

Xóa khoảng trắng thừa

Đưa toàn bộ dữ liệu về chữ viết thường

Xóa các ký tự cố ý viết dài

Chuẩn hóa Unicode (chuyển choỗi từ dạng mã hóa Window-1252 sang Unicode utf-8)

Chuẩn hóa dấu câu cho đúng vị trí

Thay các từ teen code thành dạng tiêu chuẩn

Tách từ - word tokenization. Chia câu review thành các từ

Bỏ các từ stop word không mang nhiều ý nghĩa trong quá trình training

Trích xuất đặc trưng

Công thức tổng quát

- TF (term frequency): Tính toán số lần xuất hiện của một từ trong văn bản.
- IDF (inverse document frequency): Ước lượng độ quan trọng của từ đó trong văn bản.

- TF-IDF được tính như sau:

$$TF - IDF(t, d, D) = TF(t, d) * IDF(t, D)$$

Phương pháp TF-IDF

TF-IDF (Term frequency - inverse document frequency) là một trong những kỹ thuật cơ bản trong xử lý ngôn ngữ giúp đánh giá mức độ quan trọng của một từ trong văn bản.

Nhận xét

TF-IDF hoạt động tốt với các tập tài liệu nhỏ và vừa mà không yêu cầu nhiều tài nguyên tính toán. TF-IDF chỉ dựa trên tần suất từ xuất hiện mà không hiểu được ngữ nghĩa của từ trong ngữ cảnh.

Đầu ra

Đối với các từ có điểm cao, đồng nghĩa với mức độ đặc biệt và hiếm gặp trên bộ văn bản. Trái lại, nếu có giá trị thấp thì các từ đó có thể là các từ xuất hiện đại trà trong toàn bộ tập dữ liệu.

Phần 04.

Huấn luyện và đánh giá mô hình

Phương pháp training model

Phương pháp giải quyết bài toán phân loại đa nhãn

Problem Transformation

Chia bài toán phân loại đa nhãn thành các bài toán phân loại đơn nhãn.

Adapted Algorithm

Xử lý bài toán đa nhãn một cách trực tiếp mà không thông qua biến đổi thành các bài toán phụ.

Ensemble approaches

Kết hợp nhiều classifier hoặc model để cải thiện hiệu suất phân loại đa nhãn.

Phương pháp được áp dụng trong đề tài

Binary Relevance

Mỗi nhãn sẽ được xem là một bài toán phân loại đơn nhãn riêng biệt.

Label Powerset

Xem xét các trường hợp có các nhãn là giống nhau mà gom chúng lại thành một lớp.

Classifier Chains

Xây dựng một chuỗi các classifier trong đó mỗi classifier sử dụng các dự đoán của các classifier trước đó làm các feature bổ sung.

Các chỉ số đánh giá (Evaluation Metrics)

Macro-average precision score

Macro-average precision là trung bình cộng của các precision theo từng class.

$$MacroP = \frac{\sum_{c_i \in C} P(D, c_i)}{|C|}.$$

Macro-average recall

Macro-average recall là trung bình cộng của cá recall theo từng class.

$$MacroR = \frac{\sum_{c_i \in C} R(D, c_i)}{|C|}.$$

Macro-average F1 score

Macro-average F1 score là giá trị trung bình điều hòa của macro P và macro R, được tính bằng cách tính F1 score cho từng class riêng lẻ sau đó tính giá trị trung bình.

$$MacroF1 = \frac{1}{N} \sum_{i=0}^{N} F1 \cdot$$

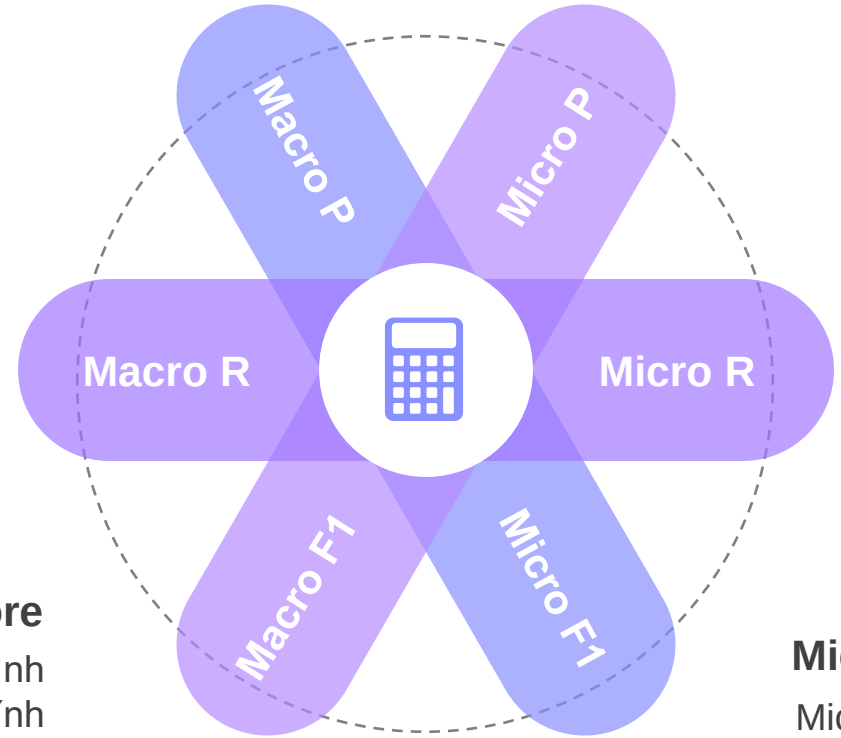

Micro-average precision score

Micro-average precision tổng hợp sự đóng góp của tất cả các class để tính toán precision tổng thể.

$$MicroP = \frac{\sum_{c_i \in C} TPs(c_i)}{\sum_{c_i \in C} TPs(c_i) + FPs(c_i)}.$$

Micro-average recall score

Micro-average recall tổng hợp sự đóng góp của tất cả các class để tính toán recall tổng thể.

$$Micro\ R = \frac{\sum_{c_i \in C} TPs(c_i)}{\sum_{c_i \in C} TPs(c_i) + FNs(c_i)}.$$

Micro-average F1 score

Micro-average F1 score là giá trị trung bình điều hòa của micro P và micro R. Được tổng hợp từ toàn bộ các nhãn trên phạm vi toàn cục.

$$MicroF1 = 2 \cdot \frac{MicroP \cdot MicroR}{MicroP + MicroR}.$$

Kết quả training và kết luận

Method	Classifier	Micro F1	Macro F1	Micro P	Macro P	Micro R	Macro R
Binary Relevance	NB	0.47084	0.45532	0.86291	0.88371	0.32420	0.31383
	RF	**0.74712**	**0.75481**	**0.86619**	**0.86918**	**0.65707**	**0.66927**
	KNN	0.27737	0.29294	0.60750	0.61529	0.17972	0.19586
	SVC	0.73163	0.73565	0.87898	0.88799	0.62671	0.62903
	LR	0.59853	0.58945	0.90414	0.91333	0.44759	0.43862
Label Powerset	NB	0.36228	0.35249	0.85716	0.87853	0.22809	0.22355
	RF	**0.61889**	**0.62140**	**0.87332**	**0.87742**	**0.47933**	**0.48277**
	KNN	0.27820	0.29374	0.60629	0.61558	0.18054	0.19645
	SVC	0.59445	0.59478	0.86718	0.88195	0.45250	0.45111
	LR	0.49325	049061	0.89388	0.90780	0.34094	033835
Classifier Chains	NB	0.47688	0.46384	0.86783	0.88586	0.32928	0.32050
	RF	**0.74509**	**0.75257**	**0.86956**	**0.87253**	**0.65195**	**0.66384**
	KNN	0.27253	0.29290	0.60642	0.61465	0.17972	0.19586
	SVC	0.73081	0.73481	0.88006	0.88873	0.62501	0.62725
	LR	0.57750	0.56709	0.90007	0.90834	0.42537	0.44645

Phương pháp cho kết quả tốt nhất (dựa theo Micro F1 score) là: *Binary Relevance*

Thuật toán học máy tương ứng cho kết quả tốt nhất là: *Random Forest*

Giá trị Accuray Score thu được từ mô hình này là: *0.7242314647377939*

Giá trị Hamming Loss thu được từ mô hình này là: *0.06672694394213381*

THE END

Cảm ơn thầy và các bạn đã lắng nghe